



MODELAGEM PREDITIVA PARA SÉRIES TEMPORAIS DE CONSUMO ELÉTRICO RESIDENCIAL: UM ESTUDO DE CASO COMPARANDO MODELOS LINEARES E DE GRADIENT BOOSTING

Matheus Emanuel Gonçalves Vieira¹ - matheusemanuel.com@gmail.com

Esly Mendes Junior² - esly.junior@gmail.com

¹Universidade Estadual de Montes Claros – Montes Claros – MG

²Universidade Estadual de Montes Claros – Montes Claros – MG

Abstract. A previsão precisa do consumo de energia elétrica é fundamental para o gerenciamento eficiente de recursos energéticos. Este trabalho apresenta o desenvolvimento e a comparação de modelos de Machine Learning para a previsão do consumo médio diário de potência ativa em uma residência, utilizando o dataset "Individual Household Electric Power Consumption" da UCI. O processo metodológico incluiu um rigoroso pré-processamento de dados, seguido de uma análise exploratória que revelou padrões cíclicos. Features baseadas em calendário foram projetadas a partir da série temporal. Foram implementados e avaliados dois modelos: uma Regressão Linear, servindo como baseline, e um modelo de Extreme Gradient Boosting (XGBoost). Para avaliação, os dados foram divididos cronologicamente, com o último ano para teste. Os resultados mostraram, de forma contraintuitiva, um desempenho superior do modelo de Regressão Linear, que alcançou um Erro Absoluto Médio (MAE) de 0.0068, em comparação com o MAE de 0.0101 obtido pelo XGBoost. A superioridade do modelo simples sugere uma forte relação linear entre as features e o alvo, destacando a importância de estabelecer baselines robustos em problemas de modelagem preditiva.

Keywords: Previsão de Séries Temporais, Consumo de Energia, Machine Learning, Regressão Linear, XGBoost

1. INTRODUÇÃO

A transição global para fontes de energia renováveis e a implementação de redes elétricas inteligentes (smart grids) têm aumentado a complexidade do gerenciamento da oferta e demanda de eletricidade. Nesse cenário, a previsão de consumo em nível de residência individual, ou IHLF (Individual Household Load Forecasting), torna-se crucial para otimizar a distribuição de recursos energéticos descentralizados e para desenvolver programas de resposta à demanda. Contudo, a modelagem do consumo residencial apresenta desafios únicos devido à sua alta volatilidade e à forte dependência de fatores como padrões de comportamento dos ocupantes, uso de eletrodomésticos e condições socioeconômicas, que geram séries temporais ruidosas e não estacionárias.

O avanço das técnicas de Machine Learning oferece ferramentas poderosas para lidar com essa complexidade. Enquanto modelos sofisticados como redes neurais e algoritmos de

boosting são frequentemente aplicados a este problema, uma questão fundamental persiste: a complexidade adicional desses modelos sempre se traduz em um ganho de performance que justifique seu uso em detrimento de abordagens mais simples e interpretáveis? Muitos estudos se concentram em otimizar algoritmos complexos, mas poucos realizam uma comparação rigorosa contra um baseline linear robusto, especialmente em cenários onde a engenharia de features desempenha um papel central.

Este trabalho busca explorar essa questão, desenvolvendo e comparando o desempenho de dois modelos de Machine Learning – a Regressão Linear e o XGBoost – para a previsão do consumo diário de energia. Utilizando um conhecido conjunto de dados público, investigamos se um modelo complexo e não linear oferece vantagens significativas sobre um modelo linear simples após uma cuidadosa etapa de engenharia de features. A análise busca não apenas encontrar o modelo mais acurado, mas também discutir as implicações práticas da relação entre complexidade, interpretabilidade e performance.

2. METODOLOGIA

A metodologia adotada neste estudo foi estruturada em quatro etapas principais: a descrição do conjunto de dados, o pré-processamento e a engenharia de features, a divisão e avaliação dos modelos, e a implementação dos algoritmos de aprendizado de máquina.

2.1 Conjunto de Dados

O estudo foi conduzido utilizando o dataset “Individual Household Electric Power Consumption”, disponibilizado pelo repositório da UC Irvine (Hebrail and Berard, 2012). O conjunto de dados contém mais de 2 milhões de medições de uma única residência na França, coletadas entre dezembro de 2006 e novembro de 2010, com frequência de um minuto. As variáveis mais relevantes para a análise estão descritas na Tabela 1. A variável alvo para nossa previsão é a ‘Global_active_power’.

Table 1: Descrição das principais variáveis do conjunto de dados.

Variável	Descrição
Global_active_power	Potência ativa total consumida (kilowatt)
Global_reactive_power	Potência reativa total consumida (kilowatt)
Voltage	Voltagem média (volt)
Global_intensity	Intensidade da corrente média (ampere)
Sub_metering_1	Consumo da cozinha (watt-hora)
Sub_metering_2	Consumo da lavanderia (watt-hora)
Sub_metering_3	Consumo do aquecedor de água e ar condicionado (watt-hora)

2.2 Pré-processamento e Engenharia de Features

A preparação dos dados foi uma etapa crítica. Inicialmente, valores ausentes, representados pelo caractere ‘?’, foram tratados. As colunas de medição foram convertidas para tipos numéricos, e as colunas de data e hora foram combinadas para criar um índice de série temporal. O problema de previsão foi então simplificado da previsão minuto a minuto para a previsão da

média diária da ‘Global_active_power’. Essa agregação temporal é uma decisão metodológica importante, pois reduz o ruído de alta frequência e a variabilidade dos dados, permitindo que os modelos foquem em capturar as tendências e sazonalidades mais relevantes (diária, semanal, anual), como ilustrado na Fig. 1.




Figure 1: Série temporal da média diária de consumo de energia ativa global (2006-2010).

Com base na análise exploratória, foi realizada a engenharia de features. Novas variáveis preditoras foram extraídas do índice temporal, como dia da semana, dia do ano, mês, ano e trimestre. A criação dessas features é o que permite que modelos de regressão tradicionais sejam aplicados a problemas de séries temporais, transformando a dependência temporal em variáveis explícitas que capturam a sazonalidade.

2.3 Divisão e Avaliação dos Modelos

Para a tarefa de previsão, os dados diários foram divididos em conjuntos de treino e teste de forma cronológica, um requisito para problemas de séries temporais. O período de treino compreendeu 1068 amostras (de 16/12/2006 a 19/11/2009), e os últimos 365 dias (de 20/11/2009 a 26/11/2010) foram reservados para o conjunto de teste, garantindo que o modelo fosse avaliado em dados “futuros” não vistos.

Foram implementados dois modelos:

- **Regressão Linear:** Utilizado como modelo de baseline, é um método paramétrico que assume uma relação linear entre as features e a variável alvo. Sua simplicidade e interpretabilidade o tornam um excelente ponto de partida (Hastie et al., 2009).
- **XGBoost:** Um modelo de Gradient Boosting baseado em árvores de decisão. Ele constrói um modelo forte de forma iterativa a partir de “modelos fracos” e é conhecido por sua capacidade de capturar relações não lineares e interações complexas entre variáveis. Foi utilizado com uma cláusula de *early stopping* para evitar sobreajuste (Chen and Guestrin, 2016).

O desempenho foi avaliado utilizando o Erro Absoluto Médio (MAE) e a Raiz do Erro Quadrático Médio (RMSE).

3. RESULTADOS E DISCUSSÃO

Após o treinamento, os modelos foram utilizados para fazer previsões no conjunto de teste. A Tabela 2 resume o desempenho quantitativo de ambos.

Table 2: Resultados comparativos de desempenho dos modelos no conjunto de teste.

Modelo	MAE	RMSE
Regressão Linear	0.0068	0.0086
XGBoost	0.0101	0.0130

Os resultados na Tabela 2 são contraintuitivos, dado que o XGBoost é um algoritmo significativamente mais complexo. A superioridade do modelo linear sugere que a relação entre as features de calendário projetadas e o consumo médio diário de energia é predominantemente linear. A agregação dos dados por dia suaviza a alta variabilidade, resultando em uma série temporal com comportamento mais regular e previsível por métodos lineares. A Fig. 2 ilustra a comparação entre os valores reais e as previsões. Visualmente, ambas as previsões seguem a tendência geral, mas a previsão da Regressão Linear (linha laranja) se mostra mais estável e alinhada aos valores reais.




Figure 2: Comparação visual entre os valores reais de consumo e as previsões geradas pelos modelos no conjunto de teste.

Este achado reforça uma máxima fundamental em Machine Learning: a complexidade de um modelo não é garantia de superioridade. Acreditamos que o sucesso do modelo linear se deve a dois fatores principais. Primeiro, a decisão de agregar os dados diariamente filtrou o "ruído" de alta frequência que poderia confundir um modelo linear, mas que um modelo complexo como o XGBoost poderia tentar (incorretamente) modelar, levando a um leve sobreajuste. Segundo, a engenharia de features transformou o problema de série temporal em um problema de regressão tabular onde as features criadas (dia da semana, mês, etc.) já continham a maior parte do poder preditivo em uma forma linearmente separável.

3.1 Limitações do Estudo

É importante reconhecer algumas limitações deste trabalho. Primeiramente, os dados são provenientes de uma única residência, o que limita a generalização dos resultados para

outros perfis de consumo. Segundo, não foram incluídas variáveis exógenas, como dados meteorológicos (temperatura, umidade), que sabidamente influenciam o consumo de energia. Por fim, não foi realizada uma otimização extensiva de hiperparâmetros para o XGBoost, que poderia potencialmente melhorar seu desempenho, embora a utilização de *early stopping* já forneça uma salvaguarda contra o sobreajuste grosseiro.

4. CONCLUSÕES

Este trabalho demonstrou o processo de desenvolvimento de modelos de Machine Learning para a previsão de consumo diário de energia residencial. Foi realizada uma comparação direta entre um modelo de Regressão Linear e um de XGBoost, revelando que o modelo mais simples superou o mais complexo, alcançando um MAE de 0.0068. O resultado evidencia a importância da engenharia de features e do estabelecimento de baselines robustos. A forte linearidade encontrada após a agregação diária dos dados e a criação de features temporais foram cruciais para o sucesso do modelo linear.

Como trabalhos futuros, sugere-se a aplicação de uma busca sistemática de hiperparâmetros (e.g., Grid Search, Bayesian Optimization) para o XGBoost. Adicionalmente, a inclusão de variáveis exógenas poderia agregar valor preditivo e favorecer modelos mais complexos capazes de capturar interações não lineares. Por fim, a aplicação de modelos de Deep Learning específicos para séries temporais, como LSTMs (Long Short-Term Memory), poderia ser investigada para capturar dependências temporais que não são explicitamente modeladas pelas features de calendário.

REFERENCES

- Chen, T. and Guestrin, C. (2016). Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, pages 785–794.
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The elements of statistical learning: data mining, inference, and prediction*. Springer Science & Business Media.
- Hebrail, G. and Berard, A. (2012). Individual Household Electric Power Consumption Dataset. <https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption>.

PREDICTIVE MODELING FOR RESIDENTIAL ELECTRICAL CONSUMPTION TIME SERIES: A CASE STUDY COMPARING LINEAR AND GRADIENT BOOSTING MODELS

Abstract. *The precise forecasting of electricity consumption is crucial for the efficient management of energy resources. This paper presents the development and comparison of Machine Learning models for forecasting the daily average active power consumption in a household, using the "Individual Household Electric Power Consumption" dataset from the UCI repository. The methodological process included a rigorous data preprocessing stage, followed by an exploratory analysis that revealed cyclical consumption patterns. Calendar-based features were engineered from the time series to serve as predictors. Two distinct models were implemented and evaluated: a Linear Regression, serving as a baseline, and an Extreme Gradient Boosting (XGBoost) model. For evaluation, the data were chronologically split, using the last year for testing. The results surprisingly showed a superior performance from the Linear Regression model, which achieved a Mean Absolute Error (MAE) of 0.0068, compared to the 0.0101 MAE obtained by XGBoost. The superiority of the simpler model suggests a strong linear relationship between the engineered features and the target, highlighting the critical importance of establishing robust baselines in predictive modeling problems.*

Keywords: *Time Series Forecasting, Energy Consumption, Machine Learning, Linear Regression, XGBoost*