



MODELAGEM PREDITIVA DE CONSUMO ELÉTRICO: UMA ANÁLISE COMPARATIVA ENTRE MÉTODOS CLÁSSICOS DE SÉRIES TEMPORAIS E ABORDAGENS DE MACHINE LEARNING

Matheus Emanuel Gonçalves Vieira¹ - matheusemanuel.com@gmail.com

Esly Mendes Junior² - esly.junior@gmail.com

¹Universidade Estadual de Montes Claros – Montes Claros – MG

²Universidade Estadual de Montes Claros – Montes Claros – MG

Abstract. A previsão precisa do consumo de energia elétrica é fundamental para o gerenciamento eficiente de recursos. Este trabalho apresenta uma análise comparativa de modelos para a previsão do consumo médio diário de potência ativa em uma residência, utilizando o dataset "Individual Household Electric Power Consumption". A metodologia inclui uma análise descritiva da série temporal, seguida pela implementação de um modelo clássico SARIMA como baseline e dois modelos de Machine Learning (ML): Regressão Linear e XGBoost, ambos utilizando features de calendário e de lag. Os modelos foram avaliados em um conjunto de teste de 365 dias. Os resultados demonstram uma falha do modelo SARIMA em capturar a dinâmica da série (MAPE de 126.12%), enquanto a abordagem de ML obteve sucesso. O modelo XGBoost se destacou como o mais preciso, alcançando um Erro Percentual Absoluto Médio (MAPE) de 18.93%. A superioridade da abordagem de ML, validada por uma análise de resíduos, destaca a eficácia da engenharia de features para transformar o problema de série temporal em um problema de regressão supervisionada de alta performance, superando drasticamente os métodos autorregressivos tradicionais.

Keywords: Previsão de Séries Temporais, Machine Learning, SARIMA, XGBoost, Engenharia de Features

1. INTRODUÇÃO

A crescente demanda por energia e a integração de fontes renováveis intermitentes nas redes elétricas impõem desafios significativos ao gerenciamento da oferta e da demanda. A previsão de consumo em nível de residência individual, ou IHLF (Individual Household Load Forecasting), é uma ferramenta crucial para a operação de redes inteligentes (smart grids), permitindo a otimização de recursos e o desenvolvimento de programas de resposta à demanda.

A modelagem de séries temporais de consumo residencial é tradicionalmente abordada por métodos estatísticos autorregressivos, como os modelos da família ARIMA (Box et al., 2015). No entanto, o avanço das técnicas de Machine Learning (ML) popularizou uma abordagem alternativa: transformar o problema de série temporal em um problema de regressão supervisionada através da engenharia de features (Hastie et al., 2009). Esta abordagem permite a

inclusão de variáveis exógenas (como calendário) e pode ser mais flexível para capturar relações complexas.

Este trabalho explora essa dualidade, realizando uma análise comparativa rigorosa. Implementamos um modelo clássico SARIMA como baseline e o comparamos com dois modelos de ML: uma Regressão Linear e um XGBoost. O objetivo é determinar se a abordagem de ML com engenharia de features pode superar um método autorregressivo consolidado e discutir as implicações dessa escolha metodológica.

2. METODOLOGIA

A metodologia adotada neste estudo foi estruturada em quatro etapas principais: (1) análise descritiva e pré-processamento da série temporal; (2) design e implementação dos modelos preditivos; (3) estratégia de avaliação de performance; e (4) ambiente computacional.

2.1 Dados e Pré-processamento

O estudo utilizou o dataset “Individual Household Electric Power Consumption” da UCI (Hebrail and Berard, 2012), contendo medições de consumo de uma residência na França (Dez/2006 a Nov/2010). A série temporal original, com frequência de um minuto, foi reamostrada para uma média diária da ‘Global_active_power’ (em kilowatt), reduzindo o ruído e focando em padrões de sazonalidade mais amplos.

2.2 Análise da Série Temporal

Antes da modelagem, foi realizada uma análise descritiva da série diária. A decomposição da série, exibida na Fig. 1, revela uma clara sazonalidade semanal (período de 7 dias) e uma tendência de longo prazo sutil. A componente de resíduos parece ser estacionária.




Figure 1: Decomposição da série temporal em tendência, sazonalidade e resíduos.

As funções de Autocorrelação (ACF) e Autocorrelação Parcial (PACF) foram plotadas (Fig. 2) para identificar a estrutura de dependência temporal. O gráfico ACF mostra um decaimento lento e picos significativos em múltiplos de 7, confirmando a forte sazonalidade semanal. O gráfico PACF indica que a correlação é mais forte com os lags imediatos. Essas características guiaram a escolha dos parâmetros para o modelo SARIMA.




Figure 2: Funções de Autocorrelação (ACF) e Autocorrelação Parcial (PACF) da série temporal.

2.3 Design dos Modelos Preditivos

Os dados foram divididos cronologicamente em treino (1061-1068 dias) e teste (365 dias). Três modelos foram implementados:

Baseline Clássico (SARIMA). Um modelo SARIMA (Seasonal AutoRegressive Integrated Moving Average) foi ajustado aos dados de treino. Os parâmetros foram definidos como $(p,d,q)=(1,1,1)$ e $(P,D,Q,s)=(1,1,1,7)$ para capturar as dinâmicas autorregressivas e a sazonalidade semanal. Este modelo usa apenas os valores passados da própria série para fazer previsões.

Modelos de Machine Learning. Para a Regressão Linear e o XGBoost, o problema foi reestruturado. A Tabela 1 detalha as variáveis de entrada (features) e a variável de saída (alvo) utilizadas.

Table 1: Design de entrada e saída para os modelos de Machine Learning.

Tipo	Variável / Feature
Entradas (X)	Dia da semana, dia do ano, mês, ano, trimestre
	‘Global_active_power‘ do dia anterior (lag 1)
	‘Global_active_power‘ da semana anterior (lag 7)
Saída (Y)	‘Global_active_power‘ (atual)

2.4 Ambiente Computacional e Implementação

Todas as análises e modelos foram desenvolvidos na linguagem de programação Python 3. A manipulação e o pré-processamento dos dados foram realizados com a biblioteca **Pandas**, enquanto as visualizações foram geradas com **Matplotlib** e **Seaborn**.

Para a modelagem estatística, a implementação do modelo SARIMA utilizou a biblioteca **Statsmodels**, que oferece um framework robusto para análise de séries temporais. O trecho de código abaixo ilustra a instancição e o treinamento do modelo.

```
1 import statsmodels.api as sm
2
3 # y_train_sarima contém os dados de treino
4 sarima_model = sm.tsa.statespace.SARIMAX(y_train_sarima,
5                                           order=(1, 1, 1),
6                                           seasonal_order=(1, 1, 1, 7))
7 sarima_results = sarima_model.fit()
```

Listing 1: Treinamento do Modelo SARIMA

Os modelos de Machine Learning foram implementados utilizando a biblioteca **Scikit-learn** para a Regressão Linear e a biblioteca **XGBoost** para o modelo de gradient boosting. O código abaixo demonstra a simplicidade da interface de treinamento para o XGBoost.

```
1 import xgboost as xgb
2
3 # X_train e y_train contêm as features e o alvo
4 xgb_model = xgb.XGBRegressor(objective='reg:squarederror',
5                               n_estimators=1000,
6                               early_stopping_rounds=50)
7 xgb_model.fit(X_train, y_train,
8               eval_set=[(X_test, y_test)],
9               verbose=False)
```

Listing 2: Treinamento do Modelo XGBoost

2.5 Métricas de Avaliação

O desempenho dos modelos foi comparado utilizando o Erro Absoluto Médio (MAE), a Raiz do Erro Quadrático Médio (RMSE) e o Erro Percentual Absoluto Médio (MAPE), uma métrica interpretável que comunica o erro como uma porcentagem do valor real.

3. RESULTADOS E DISCUSSÃO

Todos os modelos foram treinados e avaliados no conjunto de teste. A performance quantitativa é apresentada, seguida por uma análise de resíduos do melhor modelo de regressão.

3.1 Desempenho Comparativo dos Modelos

A Tabela 2 resume o desempenho dos três modelos. O resultado mais notável é a performance extremamente baixa do baseline SARIMA, com um MAPE de 126.12%, indicando que o modelo é pior do que uma previsão ingênua e falhou em capturar a dinâmica da série. Em contraste, ambos os modelos de Machine Learning apresentaram resultados robustos. O XGBoost emergiu como o modelo superior, com um MAPE de 18.93%, ligeiramente melhor que a Regressão Linear (20.50%).

Table 2: Resultados comparativos de desempenho dos modelos no conjunto de teste.

Modelo	MAE	RMSE	MAPE (%)
SARIMA (Baseline)	1.0257	1.2014	126.12
Regressão Linear	0.2015	0.2742	20.50
XGBoost	0.1808	0.2480	18.93

A Fig. 3 ilustra visualmente a disparidade. Enquanto as previsões dos modelos de ML (azul e verde) seguem de perto os valores reais (preto), a previsão do SARIMA (vermelho) diverge completamente. O sucesso da abordagem de ML reside na engenharia de features, que explicitamente fornece ao modelo informações sobre sazonalidade (mês, dia da semana) e autocorrelação (lags), uma tarefa que o SARIMA, com sua estrutura mais rígida, não conseguiu executar eficientemente para esta série temporal. A pequena vantagem do XGBoost sobre a Regressão Linear sugere a presença de relações não-lineares sutis que o modelo de boosting foi capaz de capturar.




Figure 3: Comparação visual entre os valores reais e as previsões geradas pelos modelos.

3.2 Análise de Resíduos

Para validar a abordagem de regressão e por ser o modelo mais interpretável, foi realizada uma análise dos resíduos do modelo de Regressão Linear. Idealmente, os resíduos de um bom modelo devem se comportar como um ruído branco. A Fig. 4 apresenta o histograma e o Q-Q Plot dos resíduos.




Figure 4: Análise de resíduos do modelo de Regressão Linear: (a) Histograma e (b) Q-Q Plot.

O histograma se assemelha a uma distribuição normal centrada em zero, indicando que o modelo não possui um viés sistemático. O Q-Q Plot mostra que os quantis dos resíduos seguem de perto a linha diagonal teórica da normalidade. O comportamento geral sugere que a suposição de normalidade dos erros é razoavelmente satisfeita, validando a adequação da abordagem de regressão.

4. CONCLUSÕES

Este trabalho demonstrou a superioridade de uma abordagem de Machine Learning com engenharia de features em relação a um modelo clássico SARIMA para a previsão de consumo de energia residencial. O modelo SARIMA falhou em modelar a série, enquanto os modelos de Regressão Linear e XGBoost obtiveram alta acurácia, com o XGBoost se mostrando o melhor preditor com um MAPE de 18.93%.

A principal contribuição deste estudo é a demonstração empírica de que a transformação de um problema de série temporal em um de regressão supervisionada, através da criação de features de calendário e de lag, é uma estratégia extremamente eficaz, capaz de superar drasticamente métodos autorregressivos tradicionais para séries complexas. O resultado reforça a importância da etapa de engenharia de features no sucesso de projetos de modelagem preditiva.

Para trabalhos futuros, sugere-se a otimização de hiperparâmetros dos modelos de ML e a inclusão de variáveis exógenas (como dados meteorológicos).

Disponibilidade de Dados e Códigos

O conjunto de dados utilizado neste estudo é de domínio público e está disponível no repositório UCI Machine Learning. Os códigos-fonte desenvolvidos para a análise e modelagem serão disponibilizados mediante solicitação aos autores.

REFERENCES

Box, G. E., Jenkins, G. M., Reinsel, G. C., and Ljung, G. M. (2015). *Time series analysis: forecasting and control*. John Wiley & Sons.

Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The elements of statistical learning: data mining, inference, and prediction*. Springer Science & Business Media.

Hebrail, G. and Berard, A. (2012). Individual Household Electric Power Consumption Dataset. <https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption>.

PREDICTIVE MODELING OF ELECTRICAL CONSUMPTION: A COMPARATIVE ANALYSIS BETWEEN CLASSICAL TIME SERIES METHODS AND MACHINE LEARNING APPROACHES

Abstract. *Accurate electricity consumption forecasting is crucial for efficient resource management. This paper presents a comparative analysis of models for forecasting daily average active power consumption in a household, using the "Individual Household Electric Power Consumption" dataset. The methodology includes a descriptive time series analysis, followed by the implementation of a classical SARIMA model as a baseline and two Machine Learning (ML) models: Linear Regression and XGBoost, both using calendar and lag features. The models were evaluated on a 365-day test set. The results demonstrate a failure of the SARIMA model to capture the series dynamics (MAPE of 126.12%), whereas the ML approach succeeded. The XGBoost model stood out as the most accurate, achieving a Mean Absolute Percentage Error (MAPE) of 18.93%. The superiority of the ML approach, validated by a residual analysis, highlights the effectiveness of feature engineering in transforming the time series problem into a high-performance supervised regression problem, drastically outperforming traditional autoregressive methods.*

Keywords: *Time Series Forecasting, Machine Learning, SARIMA, XGBoost, Feature Engineering*